

Análise dos Fatores de Risco e Características Associadas a ocorrência de AVC.

Luiz Augusto de Almeida de Paiva,

Marcelo do Nascimento Maximiano Filho

Escola Nacional de Ciências Estatísticas – ENCE

Rio de Janeiro, dezembro de 2024.

Resumo

Este é um estudo a respeito dos fatores associados aos casos de Acidente Vascular Cerebral (AVC), utilizando um modelo linear generalizado. A base de dados analisada incluiu informações sobre indivíduos que tiveram ou não um AVC, abrangendo variáveis como sexo, IMC, presença de diabetes, hipertensão, entre outros fatores explicativos.

O artigo destacou a relevância de variáveis específicas na explicação da ocorrência de AVC, identificando quais fatores mais contribuem para o aumento do risco, fornecendo subsídios importantes para futuras investigações e intervenções preventivas.

Palavras-Chave: Modelos Lineares Generalizados, Razão de Chances, Deviance, *dummies*.

Introdução

O presente estudo tem como objetivo identificar as variáveis e fatores associados aos casos de Acidente Vascular Cerebral (AVC). Para atingir esse propósito, será desenvolvido um modelo linear generalizado que relacione a ocorrência de AVC a diversas variáveis explicativas.

A base de dados utilizada foi extraída da plataforma Kaggle, conforme detalhado na seção bibliográfica deste artigo. A variável resposta representa a ocorrência de AVC, assumindo o valor 0 para indivíduos que não tiveram AVC e o valor 1 para aqueles que tiveram. Já as variáveis explicativas abrangem características dos indivíduos, como sexo, idade, índice de massa corporal (IMC), presença de diabetes, hipertensão, entre outros fatores.

As análises e a construção do modelo serão conduzidas utilizando o software estatístico R, com o objetivo de obter um modelo parcimonioso, ou seja, que seja ao mesmo tempo simples e capaz de explicar adequadamente os dados. Isso permitirá interpretar os resultados de maneira clara, além de medir o impacto de cada variável nos casos de AVC.

Metodologia

O primeiro passo da modelagem estatística consistiu na realização de uma análise exploratória dos dados, com o objetivo de resumir e compreender as características das variáveis presentes na base. Essa etapa permitiu identificar medidas descritivas.

A base de dados original apresentou uma distribuição desbalanceada, com apenas 4% das observações correspondendo a indivíduos que sofreram AVC. Para corrigir esse desequilíbrio, foi realizado um processo de amostragem. Decidiu-se que as observações de pessoas que tiveram AVC deveriam representar 30% do total da base. Para isso, aplicamos uma amostragem aleatória simples entre os indivíduos que nunca sofreram um AVC.

Adicionalmente, algumas variáveis foram excluídas da base original. Variáveis relacionadas à autoavaliação de saúde, saúde física e saúde mental foram removidas devido à subjetividade inerente dessas informações.

A modelagem linear generalizada foi escolhida como técnica estatística para explicar a variável resposta (ocorrência de AVC) com base em variáveis explicativas (covariáveis). Essa abordagem requer a atribuição de uma distribuição de probabilidade à variável resposta, pertencente à família exponencial, bem como a definição de um preditor linear, que é uma função composta por coeficientes e variáveis explicativas.

Outro elemento fundamental no modelo é a função de ligação, que conecta a média da variável resposta ao preditor linear, garantindo que os valores estimados estejam em conformidade com as restrições da média da variável resposta. Neste estudo, a variável resposta segue uma distribuição de Bernoulli, com parâmetro π_i , onde $i=1,2,3, \dots, N$, sendo N o número total de observações. A função de ligação escolhida foi a

logit, e o preditor linear foi composto pelas variáveis explicativas presentes na base de dados. Logo teremos a seguinte proposta de modelo:

$$\begin{cases} Y_i \sim \text{Bernoulli}(\pi_i) \\ \ln\left(\frac{\pi_i}{1 - \pi_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta} \end{cases}$$

Com base nesse modelo teórico, estimamos os coeficientes do preditor linear, verificamos a significância deles através do teste de Wald e calculamos as médias ajustadas das observações da variável resposta. Para avaliar a qualidade do modelo, verificamos a bondade de ajuste através da estatística deviance.

Além disso, os coeficientes estimados foram interpretados com base em razões de chances, permitindo medir a influência de cada covariável na chance de ocorrência de AVC. Por fim, utilizamos o modelo para realizar previsões dentro da amostra, adotando um critério de classificação. Por exemplo, se o valor ajustado fosse maior que 0,3, a variável resposta seria atribuída como 1 para aquele indivíduo.

Resultados

Como resultado da análise descritiva observamos as seguintes tabelas para nossas variáveis da nossa base.

Dimensões dos dados				
	Número de Linhas.	Número de linhas em que Y = 1.	Número de linhas em que Y = 0.	Número de Colunas.
Base Original	253680	10292	243388	22
Base Tratada	34306	10292	24014	20

Tabela 1: Base de dados original x base de dados balanceada.

Na análise exploratória, observou-se que a maioria das variáveis da base de dados é categórica ou qualitativa, representando características que indicam a presença ou ausência de um fator específico. Apenas uma variável é contínua, o índice de massa corporal (IMC). As variáveis categóricas analisadas incluem:

Variável Resposta	Contagem	
	Sucesso (Y = 1)	Fracassos (Y = 0)
Y: Indivíduo já teve AVC	10292	24014

Tabela 2: Análise da variável resposta.

Covariáveis	Sucesso (Xi = 1)	Fracassos (Xi = 0)
X ₁ : Indivíduo tem pressão alta.	17553	16753
X ₂ : Indivíduo tem colesterol alto.	16431	17875
X ₃ : Indivíduo é jovem.	4025	30281
X ₄ : Indivíduo é adulto.	16020	18286
X ₅ : Indivíduo é cardíaco.	5838	28468
X ₆ : Indivíduo pratica atividade física.	24651	9655
X ₇ : Indivíduo consome vegetais.	27090	7216
X ₈ : Indivíduo consome frutas.	21426	12880
X ₉ : Indivíduo pertence a classe média.	9632	24674
X ₁₀ : Indivíduo pertence a classe alta.	20623	13683
X ₁₁ : Indivíduo tem diabetes.	6426	27880
X ₁₂ : Indivíduo tem pré-diabetes.	694	33612
X ₁₃ : Indivíduo é fumante.	16521	17785
X ₁₄ : Sexo do indivíduo.	15083	19223

Tabela 3: Análise Covariáveis na base de dados.

As variáveis analisadas são, em sua maioria, binárias, assumindo o valor 1 quando a característica está presente nos indivíduos e 0 quando ausente. Algumas variáveis, como diabetes, renda e idade, que originalmente possuíam mais de duas categorias, foram transformadas em binárias(*dummies*) por meio de uma técnica de codificação baseada em categorias de referência. As categorias de referência escolhidas para essas variáveis foram: "indivíduo não diabético", "idoso" e "classe baixa".

Por outro lado, a única variável contínua presente na base de dados, o índice de massa corporal (IMC), pode assumir qualquer valor real positivo, representando uma medida quantitativa do estado corporal dos indivíduos.

Variável Contínua
X ₁₅ : IMC - Índice de Massa Corporal.

Tabela 4: Covariável contínua na base de dados.

IMC			
Mínimo	Média	Mediana	Máximo
13	28,56	27	98

Tabela 5: Medidas de resumo IMC.




Gráfico 1: Boxplot e histograma IMC.

A seguir, na tabela 6, temos os coeficientes estimados para as variáveis selecionadas para o modelo através do método de stepwise.

Variáveis	Coeficiente Estimado
α : Intercepto	-0,33
X ₁ : Indivíduo tem pressão alta.	0,70
X ₂ : Indivíduo tem colesterol alto.	0,31
X ₃ : Indivíduo é jovem.	-1,44
X ₄ : Indivíduo é adulto.	-0,52
X ₅ : Indivíduo é cardíaco.	1,34
X ₆ : Indivíduo pratica atividade física.	-0,28
X ₇ : Indivíduo consome vegetais.	-0,19
X ₉ : Indivíduo pertence a classe média.	-0,32
X ₁₀ : Indivíduo pertence a classe alta.	-0,95
X ₁₁ : Indivíduo tem diabetes.	0,36
X ₁₃ : Indivíduo é fumante.	0,27
X ₁₅ : IMC - Índice de Massa Corporal.	-0,01

Tabela 6: Covariáveis significativas para o modelo de stepwise.

É importante destacar que a variável “Indivíduo tem pré-diabetes” foi incorporada à sua categoria de referência. Essa escolha permite interpretar os coeficientes estimados de maneira comparativa, tomando como base indivíduos sem diagnóstico de diabetes ou pré-diabetes.

Além da significância dos coeficientes, temos que verificar a bondade de ajuste do modelo, isso é observado na deviance do modelo. Na tabela 7, observamos a tabela com os resultados do teste da deviance.

Deviance do modelo ajustado.	33237
Graus de Liberdade.	34293
Quantil 95% da distribuição da estatística Deviance.	34724,9

Tabela 7: Tabela Deviance.

Com esse resultado, o modelo passa na bondade de ajuste. Portanto, temos a seguinte equação do modelo ajustado:

$$Y_i \sim \text{Bernoulli}(\pi_i)$$

$$\left\{ \ln\left(\frac{\hat{\pi}_i}{1 - \hat{\pi}_i}\right) = -0,33 + 0,70 X_1 + 0,31 X_2 - 1,44 X_3 - 0,52 X_4 + 1,34 X_5 - 0,28 X_6 \right. \\ \left. - 0,19 X_7 - 0,32 X_9 - 0,95 X_{10} + 0,36 X_{11} + 0,27 X_{13} - 0,01 X_{15} \right.$$

Como o objetivo principal deste trabalho é verificar quais variáveis são mais associadas aos casos de AVC, faremos a interpretação das variáveis com base nas razões de chances. Na tabela 9, temos os resultados para as razões de chances.

$$\text{RAZÃO DE CHANCES} = \frac{\ln\left(\frac{\hat{\pi}_1}{1 - \hat{\pi}_1}\right)}{\ln\left(\frac{\hat{\pi}_0}{1 - \hat{\pi}_0}\right)},$$

onde 1 é presença de um fator qualquer e 0 é ausência do mesmo.

Variável /Fator	Razão de Chances: (Presença do Fator/Ausência do Fator)
X ₁ : Indivíduo tem pressão alta.	2,01
X ₂ : Indivíduo tem colesterol alto.	1,36
X ₃ : Indivíduo é jovem.	0,24
X ₄ : Indivíduo é adulto.	0,59
X ₅ : Indivíduo é cardíaco.	3,82
X ₆ : Indivíduo pratica atividade física.	0,76
X ₇ : Indivíduo consome vegetais.	0,83
X ₉ : Indivíduo pertence a classe média.	0,73
X ₁₀ : Indivíduo pertence a classe alta.	0,39
X ₁₁ : Indivíduo tem diabetes.	1,43
X ₁₃ : Indivíduo é fumante.	1,31
X ₁₅ : IMC - Índice de Massa Corporal.	0,99

Tabela 8: Tabela de razões de chances.

Além disso, é importante interpretar o que os valores ajustados representam em termos de variáveis respostas. Considerando que se $\hat{\pi}_i > 0.3$ definiremos que o valor ajustado, $\hat{Y}_i$, para a variável resposta será 1, caso contrário $\hat{Y}_i = 0$, obtivemos as seguintes quantidades de valores ajustados para $\hat{Y}_i$.

Quantidade de Valores Ajustados		Quantidade de Valores Reais	
$\hat{Y}_i = 0$	$\hat{Y}_i = 1$	$Y_i = 0$	$Y_i = 1$
20545	13761	24014	10292

Tabela 9: Tabela de valores previstos para variável resposta.

Conclusão

Na análise exploratória, com relação às variáveis, verificou-se que, exceto o IMC, todas são categóricas, indicando a presença ou ausência do fator correspondente. Após a aplicação de técnicas de seleção de variáveis, ajustou-se um modelo mais enxuto, que incluiu fatores como hipertensão, colesterol alto, diabetes, tabagismo, dificuldade para caminhar e classe social.

Inicialmente, ajustamos um modelo utilizando as covariáveis mencionadas na tabela 3 e na tabela 4. Durante a análise, constatamos através do teste de Wald que algumas dessas variáveis não eram estatisticamente significativas. Para refinar o modelo, aplicamos o método de seleção *stepwise*. Esse processo resultou em um modelo mais parcimonioso, com uma menor quantidade de variáveis, descritas na tabela 6 com seus respectivos coeficientes estimados e significativos.

O modelo final ajustado passou a incluir as variáveis mais relevantes, selecionadas com base em sua significância estatística e contribuição para a explicação dos dados. Com todos os coeficientes significativos, a bondade do ajuste foi confirmada através do teste da deviance, que testa a qualidade do ajuste do modelo, tendo como hipótese nula de que o modelo proposto explica tão bem os dados quanto o modelo maximal. Como a deviance observada (Tabela 7) foi menor que o quantil 95% da distribuição da estatística de teste, não rejeitamos a hipótese nula. Logo o modelo passa no teste de bondade de ajuste.

A interpretação dos coeficientes pode ser feita utilizando as razões de chances. Em um modelo de regressão logística (Bernoulli com função de ligação *logit*), o exponencial dos coeficientes representa a razão entre a chance de ocorrência do evento quando o fator está presente (quando a covariável assume valor 1) e a chance de ocorrência quando o fator está ausente (quando a covariável assume valor 0), assumindo que as demais variáveis permaneçam constantes. Sobre as razões de chances temos que:

1. Indivíduos com doença cardíaca 282% **mais** chance de ter AVC que indivíduos sem doença cardíaca.
2. Indivíduos com pressão alta tem 101% **mais** chance de ter AVC que indivíduos sem pressão alta.

3. Indivíduos com diabetes tem 43% **mais** chance de ter AVC que indivíduos sem diabetes ou com pré-diabetes.
4. Indivíduos com colesterol alto tem 36% **mais** chance de ter AVC que indivíduos sem colesterol alto.
5. Indivíduos fumantes alto tem 31% **mais** chance de ter AVC que indivíduos que não fumam.
6. Indivíduos jovens tem 76% **menos** chance de ter AVC que indivíduos idosos.
7. Indivíduos adultos tem 41% **menos** chance de ter AVC que indivíduos idosos.
8. A prática de atividade físicas, diminuiu em 24% a chance de ter AVC.

Analisando cada variável de forma isolada, as variáveis que mais contribuem para o aumento da chance de uma pessoa ter AVC, em ordem decrescente de impacto, são: doença cardíaca, pressão alta e colesterol alto.

Bibliografia

- Diabetes Health Indicators Dataset.
"diabetes_012_health_indicators_BRFSS2015.csv"
<https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset>
- AGRESTI, Alan. Categorical data analysis. New York: Wiley, 1990.
- · DOBSON, Annette J. An introduction to generalized linear models. London: Chapman & Hall, 1990.
- · HOSNER, D. W.; LEMESLOW, Stanley. Applied logistic regression. New York, Wiley, 1989.